C_b_2 : Recherche de modèles : Prophet

Utilisons maintenant le modèle développé par Facebook (Meta) pour modéliser des séries temporelles.

```
In [1]: import pandas as pd
        import numpy as np
        import matplotlib.pyplot as plt
        import seaborn as sns
        import os
        import locale
        import calendar
        import holidays
        from rich import print
        from datetime import date
        from references import *
        from src import *
        from prophet import Prophet
        from sklearn.metrics import mean squared error
        from sklearn.metrics import mean absolute error as mae
        from sklearn.metrics import mean_squared_error as mse
        from sklearn.model selection import TimeSeriesSplit
        import warnings
        warnings.filterwarnings("ignore")
        plt.style.use("fivethirtyeight")
        pd.options.mode.chained assignment = None
        pd.set_option("display.max_columns", 500)
        pd.set_option("display.width", 1000)
        locale.setlocale(locale.LC ALL, "fr CA.UTF-8")
       Importing plotly failed. Interactive plots will not work.
Out[1]: 'fr_CA.UTF-8'
```

```
In [2]: # %load_ext jupyter_black
import black
import jupyter_black

jupyter_black.load(
    lab=True,
    line_length=55,
    target_version=black.TargetVersion.PY311,
)
```

Prophet



Prophet is a framework for forecasting time series data based on an additive model where non-linear trends are fit with yearly, weekly, and daily seasonality, plus holiday effects. It works best with time series that have strong seasonal effects and several seasons of historical data. Prophet is robust in regard to missing data and shifts in trend, and typically handles outliers well.

Exemple qui a inspiré ce sujet

Rob Mulla

- https://youtu.be/j0eioK5edqg?si=jW2169K9XA5xdbPP
- https://www.kaggle.com/code/robikscube/time-series-forecasting-with-prophetyt/notebook

Autre exemple avec variables multiples :

Exemple / explications simples : https://stackoverflow.com/questions/54544285/is-it-possible-to-do-multivariate-multi-step-forecasting-using-fb-prophet

Import des données et créations des caractéristiques (features)

```
364 * 24 * 3,
],
fenetres=[1, 2, 3, 4, 6, 8, 12, 16, 24],
fin="20221231",
getInfoDate=True,
)

df = df.dropna()

FEATURES = df.columns.to_list()[
    1:
] # Enlevons MW en première colonne
```

Transformation pour le modèle Prophet

La cible doit être y et les valeurs de temps ds .

```
In [4]: df["ds"] = df.index
    df = df.rename(columns={"MW": "y"})

In [5]: df.head()
Out[5]:
```

y Temp hourofday quarter year dayofyear dayofmonth weekof

date								
2021-12- 23 21:00:00	32859.50	-12.3	21	4	2021	357	23	
2021-12- 23 22:00:00	32274.67	-12.8	22	4	2021	357	23	
2021-12- 23 23:00:00	31169.27	-12.8	23	4	2021	357	23	
2021-12- 24 00:00:00	30591.23	-13.1	0	4	2021	358	24	
2021-12- 24 01:00:00	30032.52	-13.2	1	4	2021	358	24	

Création des ensembles d'apprentissage et validation

```
In [6]: date_slit = "2022-01-01"
```

```
df_train = df.iloc[df.index < date_slit]
df_test = df.iloc[df.index >= date_slit]
```

Création du modèle sans les caractéristiques

Le modèle utilisera seulement les dates, mais effectuera une déduction des caractéristiques de date par lui-même.


```
In [7]: m = Prophet()
        m.fit(df train)
        forecast = m.predict(df_test.drop(columns="y"))
       INFO:prophet:Disabling yearly seasonality. Run prophet with yearly seasonali
       ty=True to override this.
       INFO:prophet:Disabling weekly seasonality. Run prophet with weekly_seasonali
       ty=True to override this.
       DEBUG:cmdstanpy:input tempfile: /var/folders/h1/zbfgvczd009f52sgp7ld62500000
       gn/T/tmpno48uf50/egihck8i.json
       DEBUG:cmdstanpy:input tempfile: /var/folders/h1/zbfgvczd009f52sgp7ld62500000
       gn/T/tmpno48uf50/vpix3pxa.json
       DEBUG:cmdstanpy:idx 0
       DEBUG:cmdstanpy:running CmdStan, num_threads: None
       DEBUG:cmdstanpy:CmdStan args: ['/opt/homebrew/anaconda3/envs/sci1402/lib/pyt
       hon3.11/site-packages/prophet/stan_model/prophet_model.bin', 'random', 'seed
       =49498', 'data', 'file=/var/folders/h1/zbfgvczd009f52sgp7ld62500000gn/T/tmpn
       o48uf50/egihck8i.json', 'init=/var/folders/h1/zbfgvczd009f52sgp7ld62500000g
       n/T/tmpno48uf50/vpix3pxa.json', 'output', 'file=/var/folders/h1/zbfgvczd009f
       52sqp7ld62500000qn/T/tmpno48uf50/prophet modelt952vqa /prophet model-2023120
       4222843.csv', 'method=optimize', 'algorithm=lbfgs', 'iter=10000']
       22:28:43 - cmdstanpy - INFO - Chain [1] start processing
       INFO:cmdstanpy:Chain [1] start processing
       22:28:43 - cmdstanpy - INFO - Chain [1] done processing
       INFO:cmdstanpy:Chain [1] done processing
```

```
In [8]: forecast.head()
```


	ds	trend	yhat_lower	yhat_upper	trend_lower	trend_uppe
	2022- 0 01-01 00:00:00	24947.323573	22694.373939	23910.008162	24947.323573	24947.32357
1	2022- 1 01-01 01:00:00	24891.227646	22205.515272	23461.679801	24887.871974	24894.587627
	2022- 2 01-01 02:00:00	24835.131718	21862.931665	23144.183827	24818.485673	24852.626820
3	2022- 3 01-01 03:00:00	24779.035790	21775.415084	23044.902682	24749.026419	24817.15075(
	2022- 4 01-01 04:00:00	24722.939862	21961.639554	23241.580182	24674.674855	24784.060418

Out[8]:

```
In [9]: fig, ax = plt.subplots(figsize=(10, 5))
fig = m.plot(forecast, ax=ax)
ax.set_title("Prédiction - modèle Prophet")
ax.set_ylabel("MW")
ax.set_xlabel("")
plt.show()
```



```
In [10]: fig = m.plot_components(forecast)
    plt.show()
```




Comparaison avec les données réelles

```
In [11]: f, ax = plt.subplots(figsize=(15, 5))
          ax.plot(
               df_test.index, df_test["y"], color="r"
          ) # Données rééelles
          fig = m.plot(forecast, ax=ax) # Prédictions
          ax.set_ylabel("MW")
          ax.set_xlabel("")
          plot = plt.suptitle("2022 - Prédiction vs Réel")
                                           2022 - Prédiction vs Réel
            1e6
           6
           2
        M
           0
          -6
                     2022-02
                                 2022-04
                                             2022-06
                                                         2022-08
                                                                      2022-10
                                                                                  2022-12
```

Nous ne pouvons pas voir grand-chose avec cette échelle.

```
In [12]: fig, ax = plt.subplots(figsize=(15, 8))
    ax.plot(df_test.index, df_test["y"], color="r")
    fig = m.plot(forecast, ax=ax)
```

```
ax.set_xbound(
    lower=datetime(2022, 1, 1),
    upper=datetime(2022, 1, 31),
)
ax.set_ylim(-10_000, 45_000)
ax.set_ylabel("MW")
ax.set_xlabel("")
plot = plt.suptitle(
    "Janvier 2022 - Prédiction vs Réel"
)
```



Nous pouvons voir que le modèle décroche complètement. Il est en mesure de reproduire les variations quotidiennes (la double bosse de demande), mais la tendance est grandement à la baisse, projetant des valeurs de demande sous zéro après une vingtaine de jours.

Cela ne fonctionne pas : essayons avec l'ajout de caractéristiques.

Création d'un modèle avec le delat T et la moyenne mobile de la température sur 24h

Ajoutons de 2 caractéristiques : Temp_MOYMOBILE_t-24h et DT_18

Comme cela fonctionnait bien dans l'autre modèle (importance relative élevée), utilisons une caractéristique supplémentaire dans ce modèle.

```
In [13]: m = Prophet()

m.add_regressor("Temp_MOYMOBILE_t-24h")
m.add_regressor("DT_18")


m.fit(df_train)
```

```
forecast = m.predict(df_test.drop(columns="y"))
INFO:prophet:Disabling yearly seasonality. Run prophet with yearly seasonali
ty=True to override this.
INFO:prophet:Disabling weekly seasonality. Run prophet with weekly seasonali
ty=True to override this.
DEBUG:cmdstanpy:input tempfile: /var/folders/h1/zbfgvczd009f52sgp7ld62500000
gn/T/tmpno48uf50/rhcobyyx.json
DEBUG:cmdstanpy:input tempfile: /var/folders/h1/zbfqvczd009f52sqp7ld62500000
gn/T/tmpno48uf50/nywyup81.json
DEBUG:cmdstanpy:idx 0
DEBUG:cmdstanpy:running CmdStan, num threads: None
DEBUG:cmdstanpy:CmdStan args: ['/opt/homebrew/anaconda3/envs/sci1402/lib/pyt
hon3.11/site-packages/prophet/stan_model/prophet_model.bin', 'random', 'seed
=99050', 'data', 'file=/var/folders/h1/zbfgvczd009f52sgp7ld62500000gn/T/tmpn
o48uf50/rhcobyyx.json', 'init=/var/folders/h1/zbfgvczd009f52sgp7ld62500000g
n/T/tmpno48uf50/nywyup81.json', 'output', 'file=/var/folders/h1/zbfgvczd009f
52sqp7ld62500000qn/T/tmpno48uf50/prophet modelqhvzoc97/prophet model-2023120
4222845.csv', 'method=optimize', 'algorithm=lbfgs', 'iter=10000']
22:28:45 - cmdstanpy - INFO - Chain [1] start processing
INFO:cmdstanpy:Chain [1] start processing
22:28:45 - cmdstanpy - INFO - Chain [1] done processing
```

```
In [14]: fig, ax = plt.subplots(figsize=(15, 8))
    ax.plot(df_test.index, df_test["y"], color="r")
    fig = m.plot(forecast, ax=ax)
    ax.set_ylabel("MW")
    ax.set_xlabel("")
    ax.set_ylim(-5_000, 45_000)


plot = plt.suptitle("2022 - Prédiction vs Réel")
```

INFO:cmdstanpy:Chain [1] done processing



Le modèle décroche encore une fois après un mois et demi environ.

```
In [15]: fig, ax = plt.subplots(figsize=(15, 8))
    ax.plot(df_test.index, df_test["y"], color="r")
    fig = m.plot(forecast, ax=ax)
    ax.set_xbound(
        lower=datetime(2022, 1, 1),
        upper=datetime(2022, 2, 28),
)
    ax.set_ylim(0, 45_000)
    ax.set_ylabel("MW")
    ax.set_xlabel("")
    plot = plt.suptitle(
        "Janvier & Février 2022 - Prédiction vs Réel"
)
```



Création d'un modèle avec toutes les caractéristiques

Comme le modèle s'est amélioré avec l'ajout de caractéristiques, essayons de les ajouter toutes.

```
In [16]: m = Prophet()


for feature in FEATURES:
    m.add_regressor(feature)

m.fit(df_train)

forecast = m.predict(df_test.drop(columns="y"))
```

```
INFO:prophet:Disabling yearly seasonality. Run prophet with yearly seasonali
ty=True to override this.
INFO:prophet:Disabling weekly seasonality. Run prophet with weekly_seasonali
ty=True to override this.
DEBUG:cmdstanpy:input tempfile: /var/folders/h1/zbfgvczd009f52sgp7ld62500000
gn/T/tmpno48uf50/awodpg7b.json
DEBUG:cmdstanpy:input tempfile: /var/folders/h1/zbfqvczd009f52sqp7ld62500000
gn/T/tmpno48uf50/3ii5qbvh.json
DEBUG:cmdstanpy:idx 0
DEBUG:cmdstanpy:running CmdStan, num threads: None
DEBUG:cmdstanpy:CmdStan args: ['/opt/homebrew/anaconda3/envs/sci1402/lib/pyt
hon3.11/site-packages/prophet/stan_model/prophet_model.bin', 'random', 'seed
=56402', 'data', 'file=/var/folders/h1/zbfgvczd009f52sqp7ld62500000gn/T/tmpn
o48uf50/awodpg7b.json', 'init=/var/folders/h1/zbfgvczd009f52sgp7ld62500000g
n/T/tmpno48uf50/3ii5qbvh.json', 'output', 'file=/var/folders/h1/zbfgvczd009f
52sqp7ld62500000qn/T/tmpno48uf50/prophet modelujvcaqyi/prophet model-2023120
4222846.csv', 'method=optimize', 'algorithm=lbfgs', 'iter=10000']
22:28:46 - cmdstanpy - INFO - Chain [1] start processing
INFO:cmdstanpy:Chain [1] start processing
22:28:46 - cmdstanpy - INFO - Chain [1] done processing
INFO:cmdstanpy:Chain [1] done processing
```

```
In [17]: fig, ax = plt.subplots(figsize=(15, 8))
    ax.plot(df_test.index, df_test["y"], color="r")
    fig = m.plot(forecast, ax=ax)
    ax.set_ylabel("MW")
    ax.set_xlabel("")
    plot = plt.suptitle("2022 - Prédiction vs Réel")
```



L'ajout de toutes les caractéristiques a complètement bousillé le modèle qui est décroché.

Pour arriver à un meilleur résultat, il faudrait faire des essais moins radicaux (2, 5, 20 caractéristiques ?)

Conclusions

Avec ces résultats préliminaires, le temps qui passe dans le projet et les résultats extrêmement intéressants que nous avons obtenus avec **XGBoost**, je prends la décision d'arrêter la modélisation avec Prophet dès maintenant.

Notre temps sera mieux utilisé à peaufiner le modèle de XGBoost que de rendre celui-ci potable.